


Машинное обучение






Резаиан Наим, канд. техн. наук

E-mail: rezaian-n@rudn.ru

1. Заведующий лабораторией искусственного интеллекта
2. Руководитель направления разработок Центра развития цифровых технологий в образовании
3. Старший преподаватель факультета искусственного интеллекта




Градиентный бустинг



Random Forest

1. Метод k ближайших соседей (Knn)
2. Линейная регрессия
3. Функция потерь
4. Метод наименьших квадратов
5. Нормальные уравнения
6. Полиномиальная регрессия
7. Регуляризация



Случайный лес

$n=1, \dots, N$

1. Для построения i -го дерева

- Сначала, как в обычном бэггинге, из обучающей выборки X выбирается с возвращением случайная подвыборка X^i того же размера, что и X
- Построить решающее дерево $b_n(x)$ по выборке $\tilde{X}$
- Дерево строится, пока в каждом листе не окажется не более n_{min} объектов
- **!** В процессе обучения каждого дерева в каждой вершине случайно выбираются q признаков **!**

2. Чтобы получить предсказание ансамбля на тестовом объекте, усредняем отдельные ответы деревьев (для регрессии) или берём самый популярный класс (для классификации)

Разложение ошибки на смещение и разброс

- Смещение $a(x)$ такое же, как у $b_n(x)$

Если базовые модели систематически ошибаются, ансамбль сохранит эту ошибку


- Разброс $a(x)$:

$$\frac{1}{N} (\text{разброс } b_n(x)) + \text{ковариация}(b_n(x), b_m(x))$$

Если базовые модели независимы, то разброс уменьшается в N раз.

Чем более похожи базовые модели, тем меньше эффект от построения композиции.

Разложение ошибки на смещение и разброс



Проблемы бэггинга

Если базовая модель окажется смещённой, то и композиция не справится с задачей

Базовую модель долго обучать и применять, дорого хранить


Идея бустинга

Возьмём простые базовые модели

Будем строить композицию последовательно и жадно

Каждая следующая модель будет строиться так, чтобы максимально
корректировать ошибки построенных моделей

Идея бустинга



Идея бустинга

$$a(x) = \frac{1}{n} \sum_{n=1}^n b_n(x)$$

Обучение первой модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, b_1(x)) \rightarrow \min_{b_1(x)}$$


Идея бустинга

$$a(x) = \frac{1}{n} \sum_{n=1}^n b_n(x)$$


Обучение N-й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, b_{N-1}(x) + b_N(x)) \rightarrow \min_{b_N(x)}$$



Идея бустинга




Идея бустинга




$b = 1$






Идея бустинга




$b = 1$





$b = 2$





Идея бустинга





b = 1





b = 2




b = 3




Идея бустинга



$$a(x) = \frac{1}{n} \sum_{n=1}^n \rho_n b_n(x) =$$



Loss function



$$Q(M) = (1 - M)^2$$

$$V(M) = \max(1 - M)$$

$$S(M) = \frac{1}{(1 + e^M)}$$

$$L(M) = \log_2(1 + e^{-M})$$

$$E(M) = e^{-M}$$

AdaBoost

$$a(x) = \frac{1}{n} \sum_{n=1}^n \rho_n b_n(x)$$

$$L(y_i, a_N(x)) = \exp(-y_i a_N(x_i)) = \exp\left(-y_i \sum_{n=1}^N \rho_n a_n(x_i)\right)$$

$$= \exp\left(-y_i \sum_{n=1}^{N-1} \rho_n a_n(x_i)\right) \cdot \exp(-y_i \rho_N a_N(x_i))$$

AdaBoost

$$a(x) = \frac{1}{n} \sum_{n=1}^n \rho_n b_n(x)$$

$$L(y_i, a_N(x)) = \exp(-y_i a_N(x_i)) = \exp(-y_i \rho_N a_N(x_i))$$

$$= \exp\left(-y_i \sum_{n=1}^{N-1} \rho_n a_n(x_i)\right) \cdot \exp(-y_i \rho_N a_N(x_i))$$

$$= \theta_i \cdot \exp(-y_i \rho_N a_N(x_i))$$

AdaBoost

i	y_i
1	+1
2	+1
3	-1
4	-1

1- Ошибка модели

$$\varepsilon_n = \sum_{i=1}^N w_i \cdot 1(y_i \neq b_n(x_i))$$

2- Коэффициент модели

$$\rho_1 = \frac{1}{2} \ln \left(\frac{1 - \varepsilon_1}{\varepsilon_1} \right)$$

3- Обновление весов

$$w_i \leftarrow w_i \cdot \exp(-y_i \rho_N a_N(x_i))$$

AdaBoost

i	y_i
1	+1
2	+1
3	-1
4	-1

1- Ошибка модели

$$\epsilon_1 = 0.25$$

2- Коэффициент модели

$$\rho_1 = \frac{1}{2} \ln(3) \approx 0.55$$

3- Обновление весов

Для правильных : $\exp(-0.55)$
 ≈ 0.58

Для ошибки : $\exp(+0.55) \approx 1.73$

AdaBoost

$b_1(x)$

i	y_i
1	+1
2	+1
3	-1
4	-1

i	y_i	новый вес	Нормировка (w_i)
1	+1	$0.25 \times 0.58 = 0.145$	0.167
2	+1	$0.25 \times 0.58 = 0.145$	0.167
3	-1	$0.25 \times 1.73 = 0.433$	0.499
4	-1	$0.25 \times 0.58 = 0.145$	0.167

AdaBoost

$b_2(x)$

i	y_i
1	+1
2	+1
3	-1
4	-1

i	y_i	новый вес	Нормировка (w_i)
1	+1	$0.167 \times 0.45 = 0.075$	0.10
2	+1	$0.167 \times 0.45 = 0.075$	0.50
3	-1	$0.499 \times 0.45 = 0.225$	0.10
4	-1	$0.167 \times 0.45 = 0.075$	0.10

AdaBoost

$b_3(x)$

i	y_i
1	+1
2	+1
3	-1
4	-1

i	y_i	новый вес	Нормировка (w_i)
1	+1	$0.10 \times 0.33 = 0.033$	0.05
2	+1	$0.50 \times 0.33 = 0.165$	0.25
3	-1	$0.30 \times 0.33 = 0.099$	0.15
4	-1	$0.10 \times 3.0 = 0.30$	0.55

AdaBoost

i	$b_1(x)$	$b_2(x)$	$b_3(x)$	$A(x)$
1	✓	✓	✓	✓
2	✓	✗	✓	✓
3	✗	✓	✓	✓
4	✓	✓	✗	✓

Градиентный бустинг

$$\{(x_i, y_i)\}_{i=1, \dots, \ell}$$

$$L(y, a)$$

$$\hat{a}(x) = \operatorname{argmin}_{f(x)} L(y, a(x))$$

$$\hat{a}(x) = a(x, \theta)$$

$$\theta = \operatorname{argmin}_{\theta} L(y, a(x, \theta))$$

Градиентный бустинг для MSE

$$a_N(x) = \sum_{n=1}^N b_n(x)$$

Обучение N-й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L(b_{N-1}(x_i) - (y_i - b_N(x_i)))^2 \rightarrow \min_{b_N(x)}$$


Градиентный бустинг для MSE

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L \left(b_N(x_i) - s_i^{(N)} \right)^2 \rightarrow \min_{b_N(x)}$$


$$s_i^{(N)} = y_i - a_{N-1}(x_i)$$

y	$a_4(x)$	$b_5(x)$
2	0	2
5	8	-3
1	0	1
-3	-10	7


Градиентный бустинг для MSE



Градиентный бустинг для MSE




Градиентный бустинг для MSE




Random Forest

- Ошибка сначала убывает, а затем выходит на один уровень
- Случайный лес не переобучается при росте N



Ошибки бустинга на обучении и тесте



Задача обучения с произвольной функцией потерь

$$a_N(x) = \sum_{n=1}^N b_n(x)$$

Обучение N-й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, a_{N-1}(x_i) + b_N(x_i)) \rightarrow \min_{b_N(x)}$$

Логистическая функция потерь

$$a_N(x) = \text{sign} \sum_{n=1}^N b_n(x)$$

$$L(y, z) = \log(1 + \exp(-yz))$$

Может, просто обучаться на остатки, как в MSE?

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \log \left(1 + \exp \left(- \left(y_i - a_{N-1}(x_i) \right) b_N(x_i) \right) \right) \rightarrow \min_{b_N(x)}$$

Если $y_i = a_{N-1}(x_i)$, то объект не участвует в обучении


Иначе $y_i - a_{N-1}(x_i) = \pm 2$

Логистическая функция потерь

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \log \left(1 + \exp \left(- \left(y_i - a_{N-1}(x_i) \right) b_N(x_i) \right) \right) \rightarrow \min_{b_N(x)}$$

$$y_i = +1, \sum_{n=1}^N b_n(x_i) = -0.5, b_n(x_i) > 0.5$$

$$y_i = +1, \sum_{n=1}^N b_n(x_i) = -100, b_n(x_i) > 100$$



На обоих объектах будет одинаково максимизироваться отступ


Задача обучения базовой модели

Обучение N-й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, a_{N-1}(x_i) + b_N(x_i)) \rightarrow \min_{b_N(x)}$$

$$\hat{a}(x) = \sum_{i=0}^{n-1} \hat{a}_i(x)$$

$$\nabla L = - \left[\frac{\partial L(y_i, a(x_i))}{\partial a(x_i)} \right]$$



Задача обучения базовой модели

Обучение N-й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, a_{N-1}(x_i) + b_N(x_i)) \rightarrow \min_{b_N(x)}$$

Посчитаем производную:

$$S_i^{(N)} = - \frac{\partial}{\partial z} L(y_i, z) \bigg|_{z = a_{N-1}(x_i)}$$

Задача обучения базовой модели

Обучение N-й модели:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left(b_N(x_i) - s_i^{(N)} \right)^2 \rightarrow \min_{b_N(x)}$$

Посчитаем производную:

$$s_i^{(N)} = - \frac{\partial}{\partial z} L(y_i, z) \bigg|_{z = a_{N-1}(x_i)}$$

Градиентный бустинг для MSE

$$\begin{aligned} S_i^{(N)} &= -\frac{\partial}{\partial z} L(y_i, z) \bigg|_{z = a_{N-1}(x_i)} = -\frac{\partial}{\partial z} \frac{1}{2} (z - y_i)^2 \bigg|_{z = a_{N-1}(x_i)} = \\ &= -(a_{N-1}(x_i) - y_i) = y_i - a_{N-1}(x_i) \end{aligned}$$

Градиентный бустинг для MSE


i	x	y
1	1	2
2	2	4
3	3	6
4	4	8

Начало:

$$a_0(x) = 0$$

Градиентный бустинг для MSE

i	x	y	a_0	$y - a_0$
1	1	2	0	2
2	2	4	0	4
3	3	6	0	6
4	4	8	0	8



ДЕРЕВО 1


$$b_1(x) = 3 \cdot I(x < 3) + 7 \cdot I(x \geq 3)$$

Обновление $\eta = 0.5$

$$a_1(x) = 0 + 0.5 \cdot b_1(x)$$

Градиентный бустинг для MSE

i	x	y	a_1	$y - a_1$
1	1	2	1.5	0.5
2	2	4	1.5	2.5
3	3	6	3.5	2.5
4	4	8	3.5	4.5



ДЕРЕВО 2


$$b_2(x) = 1.5 \cdot I(x < 3) + 3.5 \cdot I(x \geq 3)$$

Обновление $\eta = 0.5$

$$a_2(x) = 0 + 0.5 \cdot b_2(x)$$

Градиентный бустинг для MSE

i	x	y	a_2	$y - a_2$
1	1	2	2.25	-0.25
2	2	4	2.25	1.75
3	3	6	5.25	0.75
4	4	8	5.25	2.75



ДЕРЕВО 3

$$b_2(x) = 0.75.I(x < 3) + 1.75.I(x \geq 3)$$

Обновление $\eta = 0.5$

$$a_3(x) = 0 + 0.5 \cdot b_3(x)$$

Логистическая функция потерь

$$\begin{aligned} S_i^{(N)} &= -\frac{\partial}{\partial z} L(y_i, z) \bigg|_{z = a_{N-1}(x_i)} = -\frac{\partial}{\partial z} \log(1 + \exp(-y, z)) \bigg|_{z = a_{N-1}(x_i)} = \\ &= \frac{y_i}{1 + \exp(-y a_{N-1}(x_i)))} \end{aligned}$$

Градиентный бустинг для логистической функции потерь

$$\begin{aligned} S_i^{(N)} &= -\frac{\partial}{\partial z} L(y_i, z) \bigg|_{z = a_{N-1}(x_i)} = -\frac{\partial}{\partial z} \log(1 + \exp(-y, z)) \bigg|_{z = a_{N-1}(x_i)} = \\ &= \frac{y_i}{1 + \exp(-y a_{N-1}(x_i))} \end{aligned}$$

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left(b_N(x_i) - \frac{y_i}{1 + \exp(-y a_{N-1}(x_i))} \right)^2 \rightarrow \min_{b_N(x)}$$

Градиентный бустинг для логистической функции потерь

$$\frac{1}{\ell} \sum_{i=1}^{\ell} \left(b_N(x_i) - \frac{y_i}{1 + \exp(-y a_{N-1}(x_i))} \right)^2 \rightarrow \min_{b_N(x)}$$

Отступ большой положительный: $\frac{y_i}{1 + \exp(-y a_{N-1}(x_i))} \approx 0$

Отступ большой отрицательный: $\frac{y_i}{1 + \exp(-y a_{N-1}(x_i))} \approx \pm 1$

XGBOOST (Extreme Gradient Boosting)

На каждом шаге градиентного бустинга решается задача

$$\sum_{i=1}^L (b(x_i) - s_i)^2 \rightarrow \min$$

$$\sum_{i=1}^L \left(-s_i b(x_i) + \frac{1}{2} b^2(x_i) \right)^2 \rightarrow \min$$

На каждом шаге xgboost решается задача


$$\sum_{i=1}^L \left(-s_i b(x_i) + \frac{1}{2} h_i b^2(x_i) \right)^2 + \gamma J + \frac{\lambda}{2} \sum_{j=1}^J b_j^2 \rightarrow \min$$

$$h_i = \frac{\partial^2 L}{\partial z^2} \bigg|_{a_{N-1}(x_i)}$$

Вариации бустинга

ODT (oblivious decision trees)

Ограничение: на одном уровне дерева используется один и тот же предикат




Вариации CATBOOST



Способ построения дерева


Level-wise : дерево строится рекурсивно до тех пор, пока не достигнута максимальная глубина



Способ построения дерева

Level-wise: дерево строится рекурсивно до тех пор, пока не достигнута максимальная глубина

Leaf-wise: среди текущих листьев выбирается тот, чьё разбиение сильнее всего уменьшает ошибку



Выбор лучшего порога для предиката

$[x_j < t]$ как выбирать?

1- перебрать все известные значения признака

2- построить гистограмму для признака и искать пороги среди границ на гистограмме (**Histogram-based**)

3- пресемплировать объекты с близкими к нулю значениями производной (**Gradient-based One-Side Sampling**)

Неустойчивость деревьев