


Машинное обучение





Резаиан Наим, канд. техн. наук

E-mail: rezaiyan-n@rudn.ru

1. Заведующий лабораторией искусственного интеллекта
2. Руководитель направления разработок Центра развития цифровых технологий в образовании
3. Старший преподаватель факультета искусственного интеллекта



Кластериза ция



Обучение с учителем (supervised learning)

- Для каждого объекта известен ответ (класс или число)
- Даны примеры объектов с ответами
- Нужно построить модель, которая будет предсказывать ответы для новых объектов

Обучение без учителя (unsupervised learning)

Нужно найти в них внутреннюю структуру

Примеры:

- Кластеризация
- Обнаружение аномалий
- Тематическое моделирование
- Визуализация

Кластеризация

- Дано: матрица «объекты–признаки» X)

Найти:

1. Найти количество кластеров K
 2. Алгоритм кластеризации $a(x)$, который приписывает каждый объект к одному из кластеров
- Каждый кластер состоит из похожих объектов
 - Объекты из разных кластеров существенно отличаются

Зачем кластеризовать?

- Маркетинг: искать похожих клиентов
- Модерация: проверять только одно сообщение из кластера
- Соц. опросы: выделять группы схожих анкет
- Соц. сети: искать сообщества
- Выявлять типы людей и формировать поведенческие паттерны для каждого типа

Важно

- Алгоритм кластеризации не знает, чего вы хотите
- Не стоит ожидать, что при кластеризации текстов вы получите разбиение именно по темам
- Нередко кластеры оказываются неинтерпретируемыми

Отличия

Обучение с учителем	Кластеризация
Цель : минимизация функционала ошибки	Нет строгой постановки
Множество ответов известно заранее	Множество кластеров неизвестно
Конкретные способы измерения качества	Правильные ответы отсутствуют — нельзя измерить качество


Форма кластеров




Форма кластеров




Форма кластеров



Форма кластеров




Форма кластеров




Форма кластеров




Форма кластеров




Различия в результатах работы



Исходная выборка
("Mouse" dataset)



Метод 1



Метод 2

K-Means

Дано: выборка $x_1, \dots, x_\ell$

Параметр: число кластеров K

Начало: случайно выбрать K центров кластеров $c_1, \dots, c_K$

Повторять по очереди до сходимости:

- Шаг А: отнести каждый объект к ближайшему центру

$$y_i = \arg \min_{j=1, \dots, K} \rho(x_i, c_j)$$

- Шаг Б: переместить центр каждого кластера в центр тяжести

$$c_j = \frac{\sum_{i=1}^{\ell} x_i [y_i = j]}{\sum_{i=1}^{\ell} [y_i = j]}$$


K-Means




(a)




(b)




(c)



(d)




(e)




(f)

K-Means


Iteration: 1




Iteration: 2




Iteration: 3




Iteration: 4




Iteration: 5



Iteration: 6



Iteration: 7



Выбор числа кластеров



Качество кластеризации: внутрикластерное расстояние

$$J(C) = \sum_{i=1}^{\ell} \rho(x_i, c_{y_i})$$

Зависит от K

Нужно подобрать такое K, после которого качество меняется не слишком сильно

Выбор числа кластеров



Особенности K-Means

- Может работать с большими объёмами данных
- Подходит для кластеров с простой геометрией
- Требует выбора числа кластеров

Density-based clustering


Основные, граничные и шумовые точки

Каждый объект может быть одного из трёх типов:

корневой: имеющий плотную окрестность,
 $|U_\varepsilon(x)| \geq m$

граничный: не корневой, но в окрестности
корневого

шумовой (выброс): не корневой и не
граничный




Параметры DBSCAN

Размер окрестности (eps)

Минимальное число объектов в окрестности — для определения основных точек

DBSCAN

шумовые




корневой




$m = 4$ - полная окрестность
 $\epsilon = 20$ - размер окрестности

$$U_\epsilon(x) = \{u \in U : \rho(x, u) \leq \epsilon\}$$




граничный


DBSCAN




DBSCAN




DBSCAN




DBSCAN




DBSCAN




DBSCAN




DBSCAN




DBSCAN




DBSCAN




DBSCAN



DBSCAN




DBSCAN




DBSCAN


Зависимость числа кластеров от ϵ



Зависимость доли шума от ϵ




DBSCAN



(a) Clusters found by DBSCAN.

1. Выбрать точку без метки
2. Если в окрестности меньше N точек, то пометить как шумовую
3. Создать новый кластер, поместить в него текущую точку
4. Для всех точек из окрестности S :
 - (а) если точка шумовая, то отнести к данному кластеру, но не использовать для расширения;
 - (б) если точка основная, то отнести к данному кластеру, а её окрестность добавить к S
5. Перейти к шагу 1

DBSCAN



Особенности DBSCAN

Находит кластеры произвольной формы

Может работать с большими объёмами данных

Нужно подбирать размер окрестности (ϵ) и минимальное число объектов в окрестности

Графовы методы


Кластеризация по компонентам связности

Граф: вершины соответствуют объектам


Соединяем ребром объекты, расстояние между которыми меньше R

Выделяем компоненты связности

Выделение связных компонент



Выделение связанных компонент




Особенности кластеризация по компонентам связности

Быстрая и простая

Параметр — минимальное расстояние R

Проблема: непонятно, как выбрать R , если нужно получить K кластеров

Агломеративная кластеризация (Agglomerative Clustering)



Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)




Агломеративная кластеризация (Agglomerative Clustering)



Расстояние ближнего соседа




Расстояние дальнего соседа




Групповое среднее расстояние



Расстояние между центрами



Агломеративная кластеризация (Agglomerative Clustering)



Формула Ланса-Уильямса

$$R_{WS} = \alpha_U R_{US} + \alpha_V R_{VS} + \beta R_{UV} + \gamma |R_{US} - R_{VS}|$$


Расстояние ближнего соседа



Расстояние дальнего соседа




Групповое среднее расстояние



Расстояние между центрами



Агломеративная кластеризация



$$\alpha_U = \alpha_V = \frac{1}{2}, \quad \beta = 0, \quad \gamma = -\frac{1}{2}$$

$$\alpha_U = \alpha_V = \frac{1}{2}, \quad \beta = 0, \quad \gamma = \frac{1}{2}$$


$$\alpha_U = \frac{|U|}{|W|}, \quad \alpha_V = \frac{|V|}{|W|}, \quad \beta = \gamma = 0$$

$$\alpha_U = \frac{|U|}{|W|}, \quad \alpha_V = \frac{|V|}{|W|}, \quad \beta = -\alpha_U \cdot \alpha_V, \quad \gamma = 0$$

Формула Ланса-Уильямса

$$R_{WS} = \alpha_U R_{US} + \alpha_V R_{VS} + \beta R_{UV} + \gamma |R_{US} - R_{VS}|$$

Расстояние ближнего соседа




Расстояние дальнего соседа




Групповое среднее расстояние



Расстояние между центрами



Агломеративная кластеризация



$$\alpha_U = \alpha_V = \frac{1}{2}, \quad \beta = 0, \quad \gamma = -\frac{1}{2}$$

$$\alpha_U = \alpha_V = \frac{1}{2}, \quad \beta = 0, \quad \gamma = \frac{1}{2}$$

$$\alpha_U = \frac{|U|}{|W|}, \quad \alpha_V = \frac{|V|}{|W|}, \quad \beta = \gamma = 0$$


$$\alpha_U = \frac{|U|}{|W|}, \quad \alpha_V = \frac{|V|}{|W|}, \quad \beta = -\alpha_U \cdot \alpha_V, \quad \gamma = 0$$

$$\alpha_U = \frac{|S| + |U|}{|S| + |W|}, \quad \alpha_V = \frac{|S| + |V|}{|S| + |W|}, \quad \beta = \frac{-|S|}{|S| + |W|}, \quad \gamma = 0$$

Формула Ланса-Уильямса

$$R_{WS} = \alpha_U R_{US} + \alpha_V R_{VS} + \beta R_{UV} + \gamma |R_{US} - R_{VS}|$$

Расстояние ближнего соседа




Расстояние дальнего соседа



Групповое среднее расстояние



Расстояние между центрами



Агломеративная кластеризация

1: $C_1 = \{\{x_1\}, \dots, \{x_l\}\}$ - множество одноэлементных кластеров

$R_{\{x_i\}\{x_j\}} = \rho(x_i, x_j)$ - метрика (расстояние) между отдельными объектами

2: **для всех** $t = 2, \dots, l$ (t - номер итерации)

3: найти в C_{t-1} пару кластеров U, V с минимальным расстоянием R_{UV}

4: объединить их в один кластер:

$$W = U \cup V$$

$$C_t = C_{t-1} \cup \{W\} \setminus \{U, V\}$$

5: **для всех** $S \in C_t$

6: вычислить R_{WS} по формуле Ланса-Уильямса:

$$R_{WS} = \alpha_U R_{US} + \alpha_V R_{VS} + \beta R_{UV} + \gamma |R_{US} - R_{VS}|$$